데이터 불균형 대응과 폐업 예측 모델 개선

서울시 상권분석 데이터 기반 불균형 처리 및 폐업 위험도 예측 성능 향상 연구

김지우 백지윤 이민재 장은지 정현주

지도교수: 이상민 교수님

목차

01 문제정의

02 중간면담 이후 개선점

03 구현과정 및 시각화

04 구현 결과

05 향후 개선 방향

06 참고 문헌 및 역할 소개

문제 정의

기존 공공데이터 기반 모델링의 문제

데이터 불균형 문제

- 폐업 발생 비율 1:3.4
- 과포화 위험 비율 1:33
- 예측 대상 자체가 소수 클래스

예측 결과에 대한 설명 부족

- 결과만을 제공
- 내부에서 어떤 변수가 예측에 영향을 미쳤는지 확인하기 어려움
- 모델에 대한 신뢰성 및 이해력 하락

공공데이터 특성을 반영한 학습 전략

- 공공데이터는 클래스 불균형과 다양한 변수 간 상호작용 등 복잡한 특성을 가짐
- 기존의 머신러닝 모델과는 또 다른 판단 지표가 필요

창업의사결정 도구의 부족

중간면담 피드백 & 개선안

교수님 피드백

1. 데이터 불균형 문제 해결 방안 보완

2. 시각화 자료를 대폭 확대

3. 당장의 웹서비스 개발 보단 높은 퀄리티의 모델링 연구 집중

개선 내용

비용 민감 학습(Class Weight), 임계값 조정, AUC·Recall 중심 평가를 적용하여 불균형 데이터 문제를 개선

불균형 진단, 모델 검증, 변수 중요도, 공간·시계열·생존분석 등 17종 시각화를 추가하여 분석 결과를 직관적으로 제시

파생변수 추가, Feature Engineering, XGBoost 튜닝 및 다양한 실험을 수행하여 모델 성능 개선 과정을 체계적으로 검증

데이터 수집 및 전처리

베이스라인 구축 및 변수추가

- `점포_수`, `유사_업종_점포_수`, `개업_율`, `폐업_률`, `프랜차이즈_점포_수` 등의 베이스라인에서 다양한 파생변수를 단계적으로 추가하며 성능 변화를 분석하였다.

- 변수 추가에 따른 성능 향상은 제한적이었으나, 소득구간·상권업종적합도 변수가 가장 효과적이었으며, Density 기반 파생변수는 Accuracy 향상에 기여하였다.

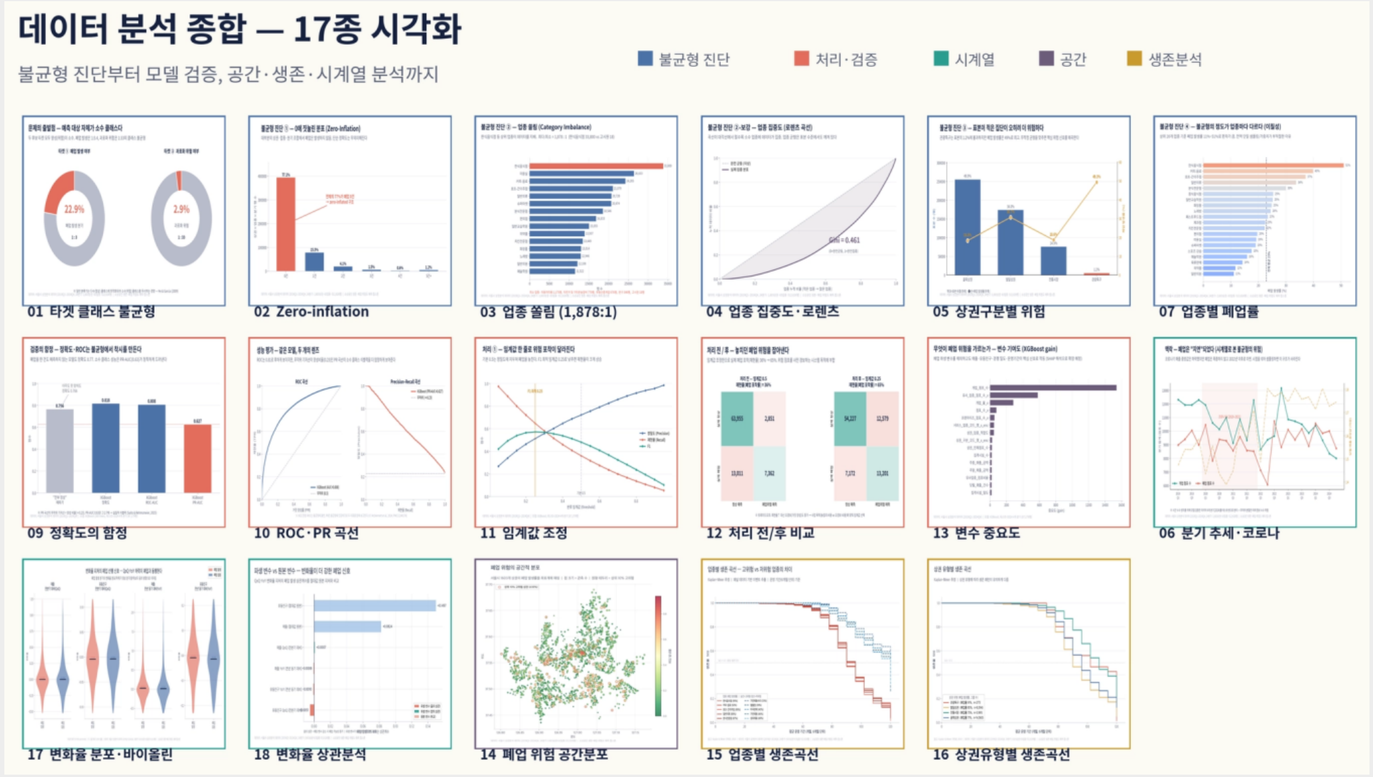
- 이를 통해 다양한 공공데이터 변수를 활용한 Feature Engineering의 효과를 확인할 수 있었다.

실험결과

LOG	실험 내용	AUC	Accuracy
LOG 0	베이스라인 검증 및 컬럼 수정	0.9055	0.8217
LOG 1	소득구간 + 상권업종적합도 변수 추가	0.9068 (+**0.0013**)	0.8218 (+**0.0001**)
LOG 2	아파트 기반 변수 추가	0.9062 (-**0.0006**)	0.8227 (+**0.0009**)
LOG 3	직장인구 변수 추가	0.9064 (+**0.0002**)	0.8233 (+**0.0006**)
LOG 4	XGBoost 파라미터 튜닝	0.9062 (-**0.0002**)	0.8212 (-**0.0021**)
LOG 5	Density 기반 파생변수 추가	0.9062 (±**0.0000**)	0.8238 (+**0.0026**)

정보분석 시각화1

데이터 불균형 및 특성 종합분석



주요 특징

1. 데이터 불균형 문제
- 예측 대상 자체가 소수 클래스
- 표준 분류기 다수 클래스 편향
- 소수 클래스 무시 경향

He & Garcia (2009) — 표준 분류기는 다수 클래스에 최적화되어 소수 클래스를 무시한다.

2. Zero-Inflated 구조
- 512,626행 중 77%가 폐업 0건 기록
- Zero-inflated 분포 구조 확인
- 극단적 0 집중 현상
-> 단순 정확도 무의미

3. 정확도·ROC의 민낯
- 폐업 0건 예측 모델 결과 -> 폐업 예측 0건 이지만, 정확도 0.766 달성
-> 정확도 지표의 무의미성 입증

4. ROC vs PR
- 같은 모델을 두 렌즈로 보았을 때, PR-AUC는 0.627로, 무작위 기준선인 0.23의 약 2.7배 수준이며 폐업 상권을 효과적으로 식별하고 있음을 확인
- 최근 일부 연구)는 ROC가 불균형에 불변이라 더 안정적이라고 반박

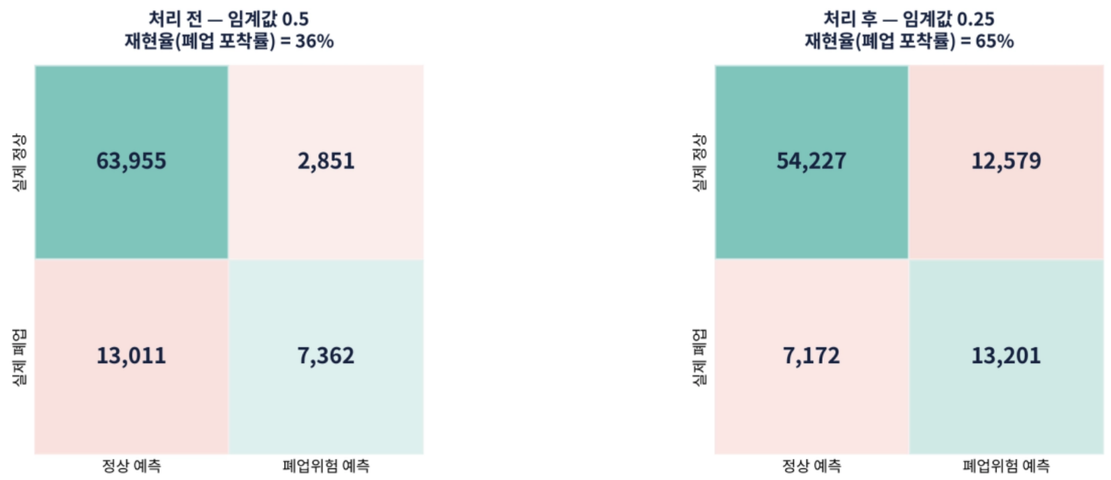
McDermott et al., 2024

정보분석 시각화2

불균형 해결

처리 전 / 후 — 놓치던 폐업 위험을 잡아낸다

임계값 조정만으로 실제 폐업 포착(재현율) 36% → 65%. 위험 점포를 사전 경보하는 시스템 목적에 부합



※ 트레이드오프: 재현율↑ 대신 오경보(거짓 양성)도 증가 → 사업 목적(놓침의 비용 vs 오경보 비용)에 맞춰 임계값 선택

4가지 측면에서의 해결책

재샘플링 (데이터 차원)

SMOTE로 소수 클래스 합성 오버샘플링
+ 다수 클래스 언더샘플링 병행
결정영역을 축소시키는 단순 복제 대신,
합성 표본을 사용해 일반화 개선

근거: Chawla et al. (2002)

비용민감 학습 (알고리즘 차원)

scale_pos_weight로 소수 클래스
오분류 비용을 가중 (=음성/양성 비율)
재샘플링 없이 손실함수에서 직접보정
트리 앙상블에 적합하여 본 프로젝트에 채택

근거: He & Garcia (2009)

임계값 조정 (의사결정 차원)

기본 0.5 대신 F1 재현율 기준으로
분류 입계값을 재탐색
확률순위(AUC)를 바꾸지 않아도
운영점(Operating point) 최적화 가능

근거: King & Zeng (2001)

평가지표 변환 (검증 차원)

정확도, ROC 대신 PR-AUC, 재현율로
소수 클래스 성능을 직접 평가
음성이 압도적일 때 정확도/ROC는
착시를 유발 -> PR곡선이 더 정보적

근거: Saito & Rehmsmeier (2015)

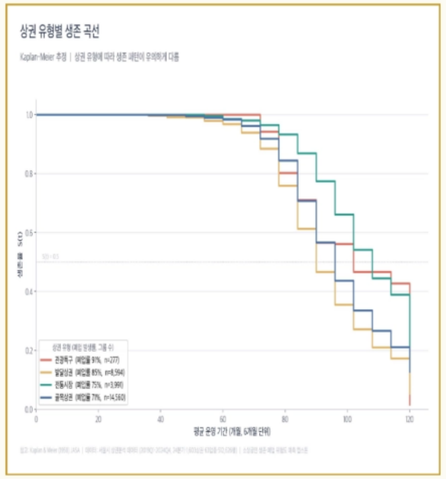
정보분석 시각화3

대표 분석 인사이트

분석 하이라이트 — 공간·생존·시계열에서 드러난 위험 신호

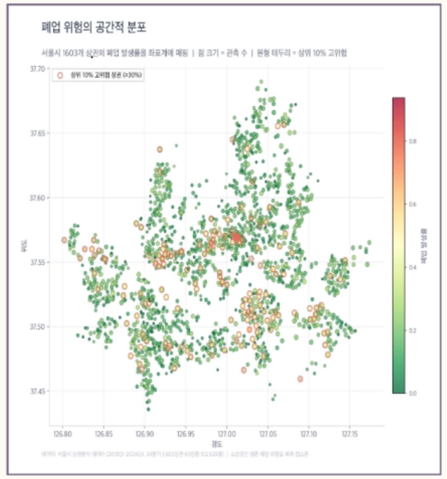
불균형 처리 외에도, 다각도 분석에서 일관된 폐업 위험 패턴을 확인했다

■ 생존분석
관광특구가 가장 빨리 폐업



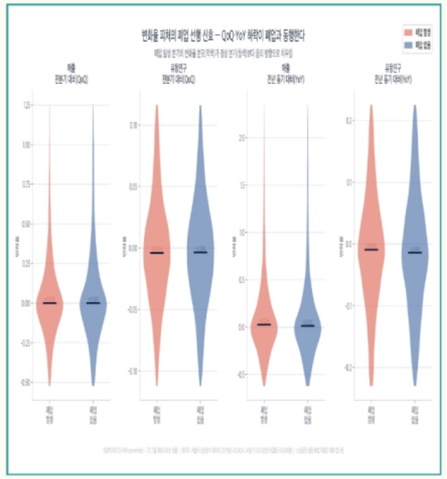
상권유형별 생존곡선 — 관광특구 폐업률 91%로
가장 가파르게 하락 (진단 결과를 재확인)

■ 공간분석
고위험 상권은 군집한다



1,603개 상권 폐업 위험을 좌표에 매핑 —
상위 10% 고위험이 특정 지역에 집중

■ 시계열
변화율 하락이 선행 신호



매출·유동인구의 QoQ·YoY 변화율이
폐업 발생군에서 음의 방향으로 치우침

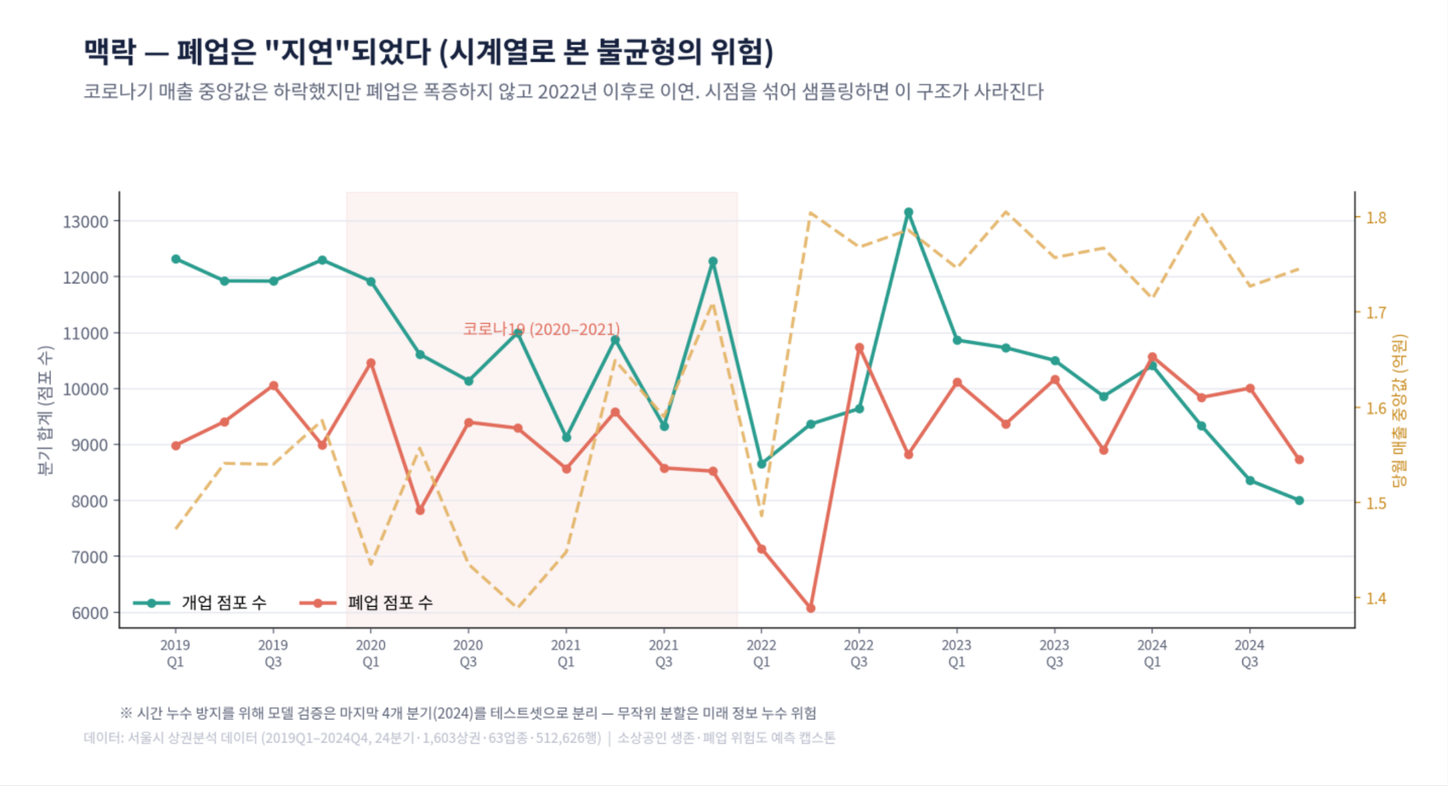
분석 결과

생존분석 결과, 관광특구의 생존율이 가장 빠르게 감소하여 다른 상권 유형보다 폐업 위험이 높은 것으로 나타났다.

공간분석에서는 폐업 위험이 높은 상권이 특정 지역에 집중되는 군집 현상을 보여 지역적 특성이 존재함을 확인하였다.

시계열 분석에서는 매출 및 유동인구 변화율이 감소하는 패턴이 폐업 발생 이전에 선행적으로 나타나 폐업 예측을 위한 주요 신호로 확인되었다.

추가 고려사항 - "COVID-19"



코로나기 매출·폐업 패턴

- 2020~2021년 매출 중앙값 하락
- 폐업은 즉시 폭증하지 않음
- 시점별 구조적 차이 존재
- 무작위 분할 시 패턴 왜곡
- 정부 긴급지원금·임대료 유예
- 폐업이 2022년 이후로 이연
- 정책 효과가 시계열에 반영됨
- 시점 맥락 보존 필수

시간 분할 검증 전략

- 검증셋: 2024년 4개 분기
- 학습셋: 2019~2023년
- 미래 정보 누수 차단
- 실전 배포 환경과 일치

구현 결과1 - 모델링 성능 비교

불균형 샘플링 기법별 최종 성능 테이블

전처리 기법 (Sampling)	모델 구분 (Model)	ROC-AUC	PR-AUC (주 지표)	F1-Score	Accuracy
Baseline (완전 무처리, 가중치 1.0)	XGBoost	0.9069	0.3250	0.1251	0.9700
	LightGBM	0.9077	0.3257	0.1273	0.9700
	Ensemble (XGB 0.3:LGB 0.7)	**0.9080**	**0.3263**	**0.1280**	**0.9700**
Cost-Sensitive (비용민감학습, scale_pos_weight)	XGBoost	0.9076	0.3135	0.2379	0.8334
	LightGBM	0.9089	0.3170	0.2351	0.8297
	Ensemble (XGB 0.3:LGB 0.7)	**0.9089**	**0.3171**	**0.2361**	**0.8310**
SMOTE (오버샘플링)	XGBoost	0.8883	0.2460	0.2965	0.9065
	LightGBM	0.8857	0.2376	0.3057	0.9156
	Ensemble (XGB 0.3:LGB 0.7)	0.8879	0.2422	0.3042	0.9132
Random Under-sampling (RUS)	XGBoost	0.9065	0.3006	0.2322	0.8279
	LightGBM	0.9062	0.3034	0.2288	0.8241
	Ensemble (XGB 0.3:LGB 0.7)	0.9064	0.3031	0.2294	0.8250
SMOTE + RUS (Hybrid)	XGBoost	0.9011	0.2735	0.2579	0.8608
	LightGBM	0.9009	0.2753	0.2570	0.8603
	Ensemble (XGB 0.3:LGB 0.7)	0.9013	0.2755	0.2571	0.8605

의의 및 해석

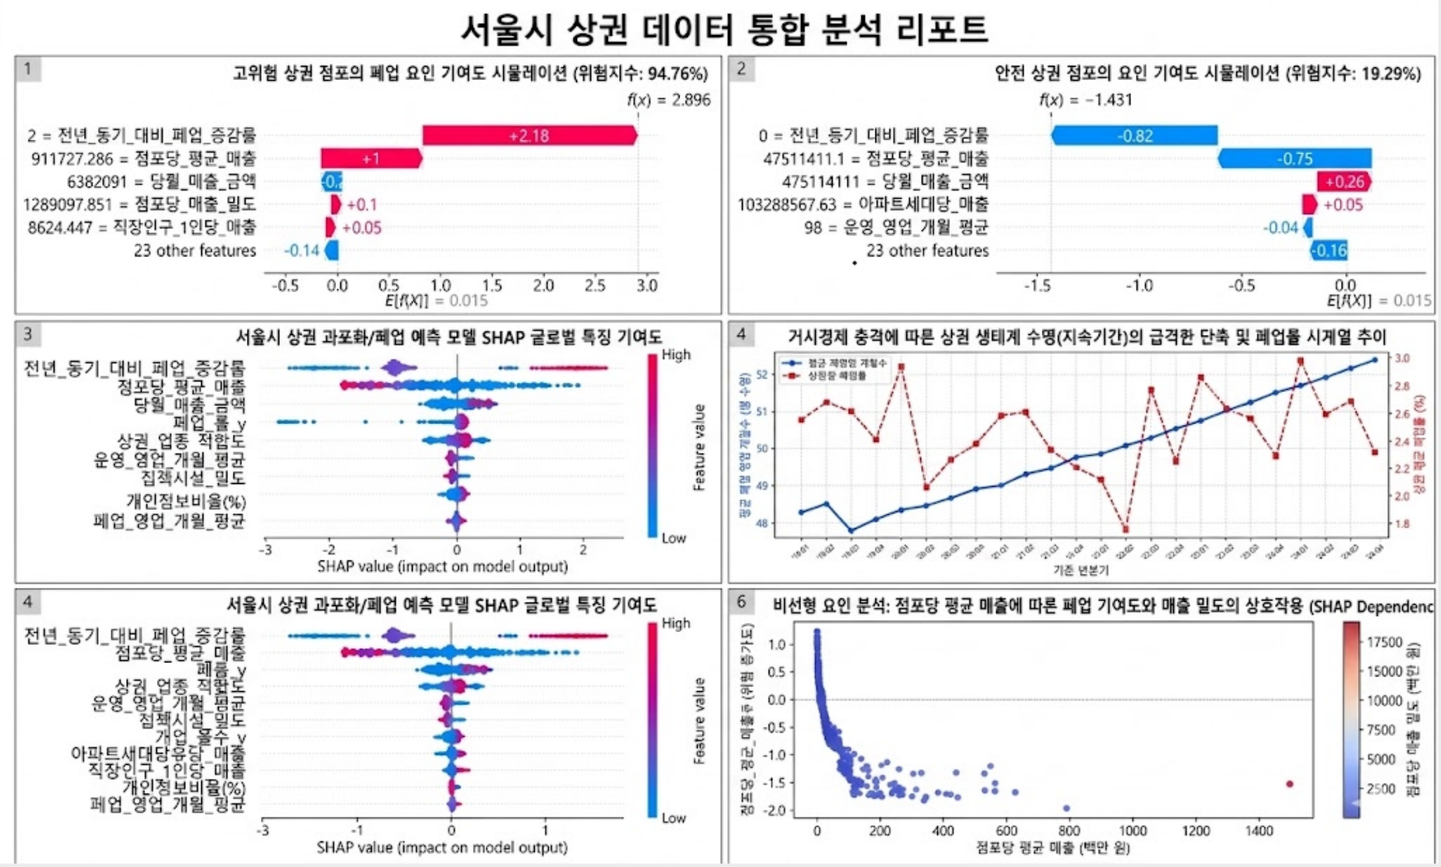
- PR-AUC와 F1-Score를 핵심 평가 지표로 선정하여, 불균형 데이터 환경에서 소수 클래스 예측 성능을 중점적으로 평가

- SMOTE 기반 오버샘플링은 과도한 가상 데이터 생성으로 False Positive가 증가하여 PR-AUC가 크게 감소하는 한계를 확인하였다.

- 이에 따라 비용 민감 학습(scale_pos_weight)을 적용하고, XGBoost + LightGBM Soft Voting Ensemble과 Threshold 최적화(0.25)를 결합하여 가장 안정적이고 우수한 예측 성능을 달성하였다.

구현 결과2 - SHAP

SHAP XAI 분석 결과



의의 및 해석

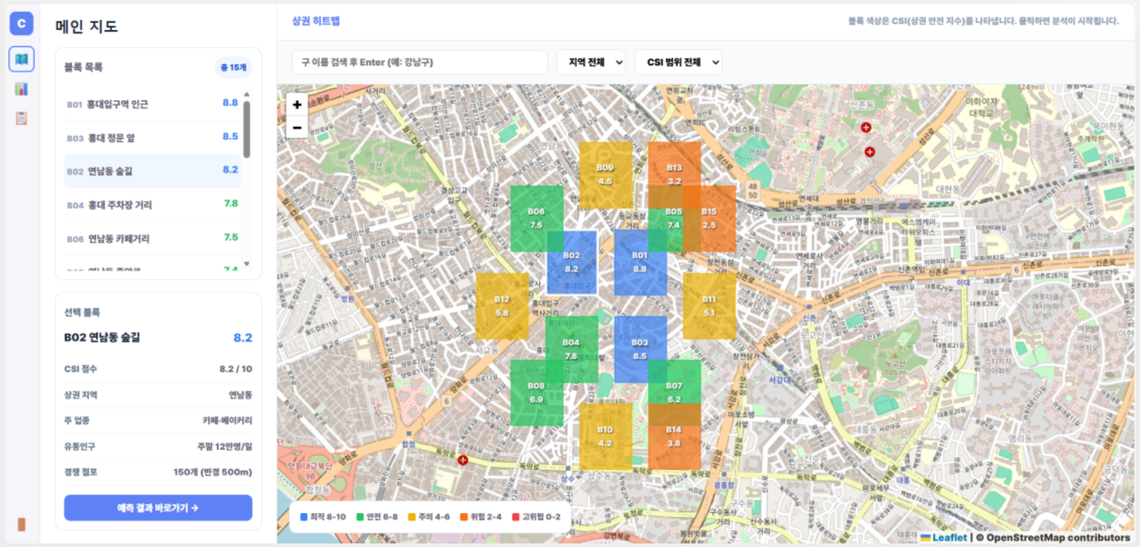
- **고위험 상권**에서는 전년 동기 대비 폐업 증가율, 점포당 평균 매출, 점포당 매출 밀도 등이 폐업 위험을 높이는 주요 요인으로 나타남
- **안전 상권**에서는 동일 변수들이 위험도를 낮추는 방향으로 작용하여 예측 결과의 근거를 확인함
- **SHAP Dependence Plot을 통해** 변수 간 비선형 관계와 상호작용을 분석하여, 단순 중요도뿐 아니라 변수 영향의 변화 양상까지 확인하였다.

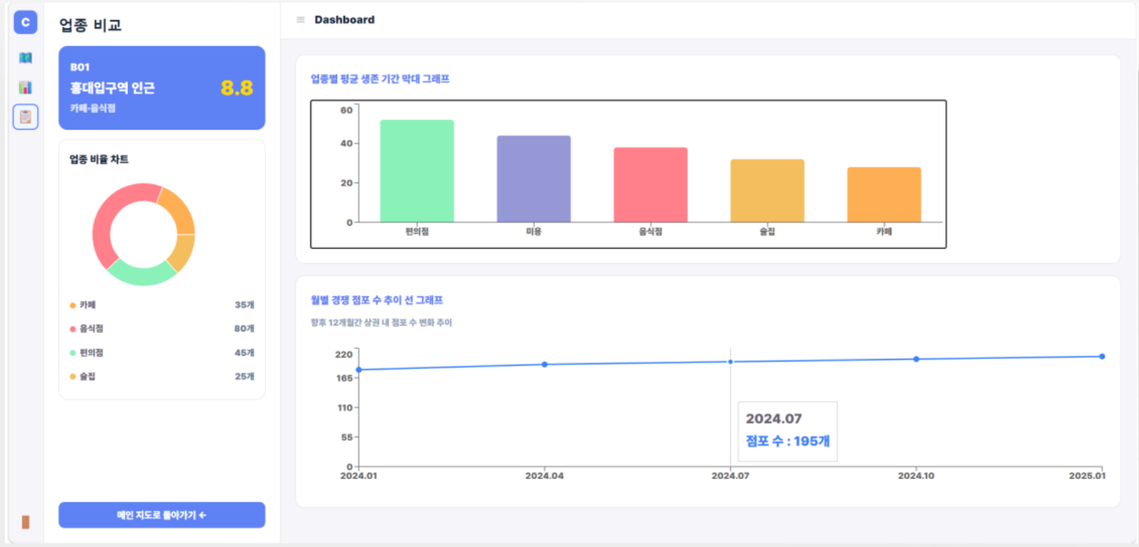
선행 연구와의 비교

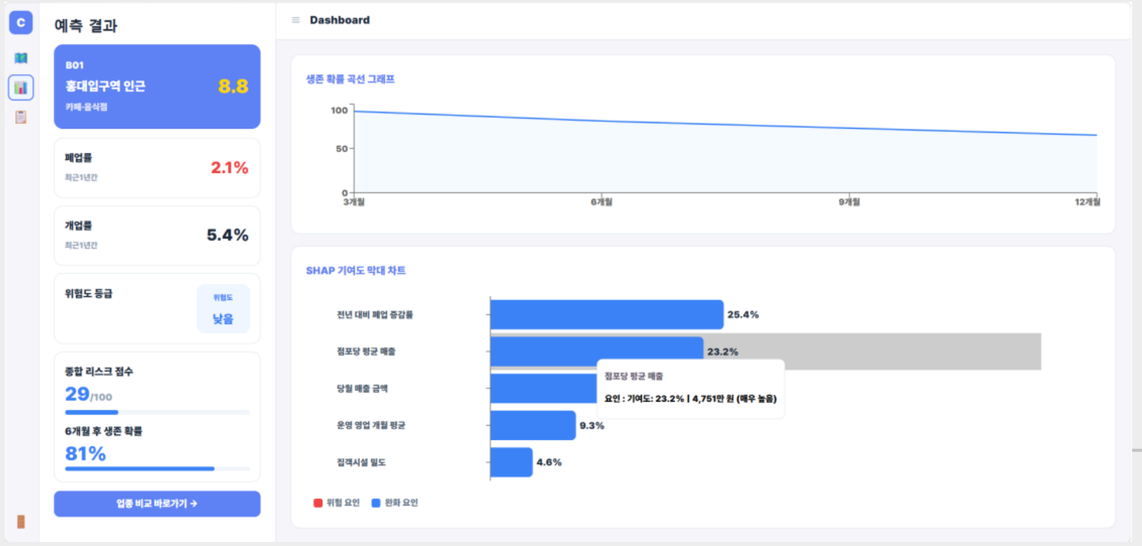
- 기존 연구가 요식업 중심의 단일 업종 분석에 초점을 맞춘 반면, 본 프로젝트는 전 업종을 대상으로 폐업 위험을 예측하였다.
- 공공데이터포털, 서울 열린데이터 등 5종 데이터를 융합하고, 기초구역 단위의 초정밀 공간분석을 적용하여 분석의 정밀도를 높였다.
- 집객시설 밀도 등 다양한 파생변수를 추가한 XGBoost 모델을 구축하여 AUC 0.90의 높은 예측 성능을 달성하였다.

IEEE Access 2022
대한산업공학회지 2024

향후 개선 방향 – 웹설계







향후 발전과제

개발한 XGBoost 폐업 예측 모델을 웹 서비스와 연계하여 사용자가 상권 정보를 조회하고 폐업 위험도를 직관적으로 확인할 수 있는 플랫폼으로 발전시킬 예정, 또한 지도 기반 시각화, 상권 비교 분석, 주요 영향 요인 제공 기능 등을 추가하여 예비 창업자와 소상공인의 의사결정을 지원하는 서비스로 확장할 계획

참고문헌

해외 논문 (불균형·모델 파트)

1. Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research, 16, 321–357.
2. He, H., & Garcia, E. A. (2009). Learning from Imbalanced Data. IEEE Transactions on Knowledge and Data Engineering, 21(9), 1263–1284.
3. King, G., & Zeng, L. (2001). Logistic Regression in Rare Events Data. Political Analysis, 9(2), 137–163.
4. Saito, T., & Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. PLoS ONE, 10(3), e0118432.
5. (보강·반론) ROC가 불균형에 견고하다는 최근 논의 — McDermott et al. (2024), PMC11240176.
6. Kaplan, E. L., & Meier, P. (1958). Nonparametric estimation from incomplete observations. Journal of the American Statistical Association, 53(282), 457–481.
7. "A Unified Approach to Interpreting Model Predictions" - Lundberg & Lee (2017)

국내 논문 (공간·생존·시계열 파생 피처 파트 - DBpia)

8. 서울시 발달상권과 골목상권의 일반음식점 생존특성 연구 - 김동준·이창효·이승일 (2019)
9. 업종별 창업 및 폐업의 지리적 특성 분석 - 이금숙·박소현 (2019)
10. 신용카드 빅데이터를 활용한 개인사업자 창업과 폐업 분석 - 김준호·김형중 (2019)
11. 사업체의 생존·폐업 기간을 활용한 서울시 상업공간의 변화분석 - 최은준·천상현·이수기 (2021)
12. 머신러닝 기법을 활용한 자영업자 폐업 예측 모형 연구: 서울시 25개 자치구를 중심으로 - 장제훈 (2021)
13. 골목상권 매출액 데이터를 활용한 성장-쇠퇴 유형화와 성장상권 영향요인 분석 — 코로나19 전후를 대상으로 - 박지완·전이봄·이승일 (2023)
14. 대한산업공학회지 - 장호준 외 (2024)
15. 발달상권과 골목상권에 위치한 음식점의 생존과 폐업 비교: 이태원 지역을 중심으로 - 정동규·윤희연 (2017)

팀원 및 역할

김지우

프로젝트 전체 일정 관리 및 4티어 시스템(React-Spring-FastAPI-PostGIS) 아키텍처 설계, 팀원별 데이터 분석 트랙 통합을 통한 파이프라인 고도화 리드, 비용민감학습 및 SHAP을 활용한 설명 가능한 앙상블 모델링 방향성 수립

백지윤

베이스라인 데이터셋 수집, DB·ERD 및 REST API 설계, Spring Boot 백엔드 구현, 공간·생존(Kaplan-Meier)·시계열 파생피처 분석을 통한 다각도 시각화 트랙 구축

이민재

데이터 수집·전처리 및 XGBoost 기반 파생변수 설계 및 모델링 성능 성능 평가(AUC, Precision-Recall 등) 및 결과 분석 진행, ppt제작 및 발표

장은지

데이터 수집·전처리부터 피처 엔지니어링, 불균형 진단·처리, 분석 시각화까지 데이터 파이프라인과 분석·시각화를 담당

정현주

서울시 공공데이터 수집·전처리 및 생존 분석 EDA, XGBoost/LightGBM 폐업 예측 모델 실험 및 SHAP 기반 설명 가능한 피처 분석, React/Vite 기반 상권 분석 대시보드 구현 및 다각도 시각화 트랙 구축

감사합니다!